

TÓM TẮT

Báo cáo hệ thống hóa quá trình phát triển của họ mô hình YOLO và tập trung phân tích kiến trúc YOLO26 do Ultralytics công bố năm 2026. YOLO26 giữ cấu trúc single-stage gồm backbone, neck và detection head, đồng thời thay đổi đường hồi quy hộp và cơ chế huấn luyện thông qua DFL-free regression, dual-head cho suy luận end-to-end không cần NMS, Progressive Loss, Small-Target-Aware Label Assignment (STAL) và optimizer MuSGD. Paper chính thức công bố các biến thể n/s/m/l/x đạt 40,9-57,5 mAP trên COCO với độ trễ TensorRT T4 1,7-11,8 ms. Phần ứng dụng tập trung vào giao thông Việt Nam, đối chiếu các nguồn dữ liệu và dự án gồm bộ dữ liệu CCTV đô thị Đà Nẵng 2026, UIT-VinaDeveS22, UIT-Drone4/UIT-Drone7, UIT-ADrone, HCMCTrafficDataset, AIC HCMC 2020 và các hệ thống camera AI đang vận hành tại Hà Nội, Thành phố Hồ Chí Minh. Các nguồn công khai về hệ thống đô thị không xác nhận detector bên trong là YOLO26; vì vậy YOLO26 được phân tích ở vai trò tăng phát hiện đối tượng, còn tracking, đếm xe, nhận diện vi phạm, ước lượng tốc độ và nhận dạng biển số được tách thành các mô-đun độc lập.

Từ khóa: YOLO, YOLO26, object detection, giao thông Việt Nam, vehicle detection, traffic surveillance, edge AI.

MỤC LỤC

TÓM TẮT	1
CHƯƠNG 1. TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN ĐỐI TƯỢNG VÀ YOLO	3
CHƯƠNG 2. QUÁ TRÌNH PHÁT TRIỂN CỦA HỌ MÔ HÌNH YOLO	5
CHƯƠNG 3. PHÂN TÍCH KIẾN TRÚC YOLO26	7
CHƯƠNG 4. YOLO26 TRONG BỐI CẢNH GIÁM SÁT GIAO THÔNG VIỆT NAM	12
CHƯƠNG 5. THẢO LUẬN VÀ KẾT LUẬN	16
TÀI LIỆU THAM KHẢO	18

CHƯƠNG 1. TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN ĐỐI TƯỢNG VÀ YOLO

1.1. Phát hiện đối tượng là gì?

Phát hiện đối tượng (object detection) trả lời đồng thời hai câu hỏi: trong ảnh có đối tượng gì và đối tượng nằm ở đâu. Đầu ra điển hình của một detector gồm nhãn lớp, độ tin cậy và một hộp giới hạn (bounding box). Khác với image classification chỉ gán một nhãn cho toàn ảnh, object detection phải xử lý nhiều đối tượng xuất hiện đồng thời và phải xác định vị trí của từng đối tượng.

Trong giao thông, bài toán này xuất hiện trực tiếp ở camera giám sát, hệ thống hỗ trợ lái và xe tự hành. Đối tượng quan tâm thường gồm ô tô, xe buýt, xe tải, xe máy, người đi bộ hoặc các đối tượng hạ tầng. Paper YOLO26 xem autonomous driving và surveillance là những nhóm ứng dụng điển hình của real-time object detection, đặc biệt khi mô hình phải chạy trên phần cứng có giới hạn độ trễ và điện năng. [1]

1.2. Vì sao YOLO được sử dụng rộng rãi trong real-time detection?

YOLOv1 đưa object detection về một bài toán hồi quy thống nhất: một mạng nơ-ron nhận toàn bộ ảnh và dự đoán trực tiếp bounding box cùng xác suất lớp trong một lần đánh giá. Paper CVPR 2016 báo cáo mô hình YOLO cơ sở chạy 45 FPS và Fast YOLO đạt 155 FPS trên phần cứng thời điểm đó. Các giá trị này không được dùng để so sánh trực tiếp với benchmark GPU hiện nay do khác phần cứng, framework và quy trình đo. [3]

Triết lý thiết kế của YOLO tập trung vào cân bằng accuracy và latency. Các thế hệ sau thay đổi backbone, cơ chế hợp nhất đặc trưng, head, label assignment và hậu xử lý để thay đổi quan hệ giữa độ chính xác và tốc độ suy luận.

1.3. Các khái niệm cần nắm trước khi đọc YOLO26

- Backbone: phần trích xuất đặc trưng từ ảnh. Các tầng đầu giữ thông tin biên/texture; các tầng sâu mang ngữ nghĩa cao hơn.
- Neck: phần hợp nhất đặc trưng nhiều mức phân giải để detector đồng thời xử lý vật thể nhỏ, vừa và lớn.
- Detection head: phần biến feature map thành dự đoán lớp và tọa độ bounding box.
- Anchor-free: không phụ thuộc vào tập anchor box có kích thước/tỷ lệ định trước; cách thiết kế này trở nên phổ biến trong các YOLO hiện đại.
- NMS (Non-Maximum Suppression): hậu xử lý loại các bounding box trùng lặp dựa trên confidence và độ chồng lấp. YOLO26 mặc định hướng tới đường suy luận không cần

NMS. [1], [7]

- DFL (Distribution Focal Loss): cách hồi quy tọa độ box dưới dạng phân phối trên các bin. YOLOv8 và YOLO11 dùng DFL; YOLO26 bỏ DFL và quay về hồi quy trực tiếp. [1], [7]

1.4. Chỉ số đánh giá tối thiểu

Intersection over Union (IoU) đo mức chồng lấp giữa bounding box dự đoán và ground truth: $\text{IoU} = \text{diện tích giao} / \text{diện tích hợp}$. Precision = $\text{TP} / (\text{TP} + \text{FP})$ phản ánh tỷ lệ dự đoán dương tính đúng; Recall = $\text{TP} / (\text{TP} + \text{FN})$ phản ánh khả năng tìm đủ đối tượng. Trong object detection hiện đại, mAP@50:95 là chỉ số tổng hợp phổ biến vì trung bình AP trên nhiều ngưỡng IoU từ 0,50 đến 0,95.

Đối với hệ thống real-time, mAP không đủ. Cần báo cáo latency trên đúng runtime và phần cứng đích. Một mô hình có mAP cao hơn nhưng latency vượt ngân sách thời gian trên CPU hoặc thiết bị edge sẽ không đáp ứng yêu cầu real-time của hệ thống. Đây là lý do paper YOLO26 trình bày đồng thời accuracy và latency. [1]

CHƯƠNG 2. QUÁ TRÌNH PHÁT TRIỂN CỦA HỌ MÔ HÌNH YOLO

2.1. YOLO không phải một dòng phiên bản do một nhóm duy nhất phát triển

Sau các phiên bản đầu của Joseph Redmon và cộng sự, tên gọi YOLO được nhiều nhóm nghiên cứu và tổ chức sử dụng. Vì vậy, YOLOv5, YOLOv6, YOLOv7, YOLOv9, YOLOv10, YOLOv12, YOLOv13 và YOLO26 không phải đều do cùng một nhóm tác giả phát triển. Bảng tổng hợp kiến trúc YOLO26 cho thấy rõ sự phân tán này qua cột tác giả và các đổi mới khác nhau. [2]

Các mốc YOLO trong báo cáo được trình bày theo nhóm phát triển và đóng góp kỹ thuật, thay vì giả định mỗi số phiên bản kế thừa trực tiếp toàn bộ phiên bản đứng ngay trước nó.

Bảng 2.1. Các mốc phát triển tiêu biểu của họ YOLO

Nguồn: Tổng hợp từ [2]-[6], [7].

Mốc	Nhóm phát triển	Đổi mới chính
YOLOv1 (2016)	Redmon et al.	One-stage thống nhất; dự đoán box và class trực tiếp từ ảnh.
YOLOv2 / YOLO9000 (2016-2017)	Redmon, Farhadi	Anchor boxes, Batch Normalization, dimension clustering.
YOLOv3 (2018)	Redmon, Farhadi	Darknet-53, residual blocks, dự đoán đa tỉ lệ.
YOLOv4 (2020)	Bochkovskiy et al.	CSPDarknet53, PANet, SPP; bag-of-freebies/bag-of-specials.
YOLOv5 (2020)	Ultralytics	PyTorch, thiết kế mô-đun, định hướng triển khai; phổ biến mạnh trong thực hành.
YOLOv6 (2022)	Meituan	EfficientRep, head tách, thiết kế anchor-free ở các bản hiện đại.
YOLOv7 (2022)	Wang et al.	E-ELAN, re-parameterized convolution, tối ưu trainable bag-of-freebies.
YOLOv8 (2023)	Ultralytics	Anchor-free, decoupled head, DFL trong box regression.
YOLOv9 (2024)	Wang et al.	Programmable Gradient Information (PGI), GELAN.
YOLOv10 (2024)	Wang et al.	Consistent dual assignments, huấn luyện NMS-free end-to-end.
YOLO11 (2024)	Ultralytics	C3k2 và các tối ưu module/scale cho họ Ultralytics.
YOLOv12 (2025)	Tian et al.	Attention-centric; Area Attention và R-ELAN cho real-time detection.
YOLOv13 (2025)	Lei et al.	HyperACE, FullPAD, mô hình hóa tương quan bậc cao bằng hypergraph.

Mốc	Nhóm phát triển	Đổi mới chính
YOLO26 (2026)	Ultralytics	DFL-free, dual-head NMS-free, MuSGD, Progressive Loss, STAL.

2.2. Các chuyển dịch kỹ thuật chính

Giai đoạn YOLOv1-YOLOv4 chủ yếu hoàn thiện nền tảng CNN, multi-scale prediction và feature aggregation. Từ YOLOv8 trở đi, xu hướng anchor-free và head tách classification/regression trở nên rõ hơn. YOLOv10 đưa NMS-free training thành một mục tiêu thiết kế thông qua consistent dual assignments. YOLOv12 đẩy attention vào trung tâm kiến trúc nhưng vẫn cố giữ tốc độ real-time, trong khi YOLOv13 dùng hypergraph để mô hình hóa tương quan nhiều-đến-nhiều giữa vị trí và thang đặc trưng. [4]-[6]

Paper YOLO26 tập trung vào bốn giới hạn được xác định trong các thế hệ trước: chi phí của DFL trong detection head, phụ thuộc NMS khi suy luận, zero-positive assignment đối với một số vật thể rất nhỏ và lịch huấn luyện dài với SGD. Trọng tâm thiết kế chuyển sang tối ưu đồng thời train, export và inference thay vì chỉ tăng capacity của mạng. [1]

2.3. Ghi chú về YOLOv14

Tháng 8/2026 xuất hiện preprint YOLOv14, tập trung vào các điều kiện ảnh fisheye, panorama, drone và game-rendered. Bản v3 ghi trạng thái "Preprint. Under review". Tài liệu này được sử dụng như nguồn tham khảo mở rộng; phần kiến trúc YOLO26 dựa trên paper và mã nguồn Ultralytics. [12]


CHƯƠNG 3. PHÂN TÍCH KIẾN TRÚC YOLO26

3.1. Mục tiêu thiết kế: end-to-end và edge-first

YOLO26 được Ultralytics xây dựng trên nền YOLO11. Paper chính thức mô tả bốn vấn đề chính cần xử lý: phụ thuộc NMS, detection head nặng do DFL, lịch huấn luyện dài và hiện tượng label assignment không cấp positive sample cho một số vật thể cực nhỏ. Các thay đổi của YOLO26 giữ lại khung YOLO và tập trung vào những thành phần tạo chi phí trong train và deployment. [1]

YOLO26 được phân tích như một kiến trúc kế thừa YOLO11 với các thay đổi tập trung vào hiệu quả train và inference. Preprint phân tích kiến trúc mô tả thiết kế tổng thể vẫn là single-stage, end-to-end detector; các thay đổi nhằm giảm chi phí tính toán và phụ thuộc vào hậu xử lý. [2]

3.2. Kiến trúc tổng thể



Hình 3.1. Kiến trúc tổng thể YOLO26: Backbone - Neck - Detect Head

Nguồn: Jocher et al. [1], Supplementary Figure S1.

Theo sơ đồ chính thức, ảnh 640 x 640 x 3 đi qua backbone gồm các khối Conv và C3k2, sau đó qua SPPF và C2PSA. Neck thực hiện upsample, concat và các khối C3k2 để hợp nhất đặc trưng nhiều thang. Cuối cùng, ba nhánh Detect nhận feature map ở các mức khác nhau. Cấu

trúc này bảo toàn triết lý multi-scale của YOLO: đặc trưng có độ phân giải cao hơn ưu tiên vật thể nhỏ, trong khi đặc trưng sâu hơn có receptive field lớn hơn hỗ trợ vật thể lớn và ngữ nghĩa phức tạp. [1]

Ranh giới "backbone" và "neck" được vẽ khác nhau giữa hai nguồn. Preprint [2] mô tả SPPF như phần mở đầu của neck, trong khi Supplementary Figure S1 của paper chính thức [1] đặt SPPF và C2PSA ở cuối backbone. Phần trình bày sử dụng cách phân chia của paper chính thức; thứ tự module không thay đổi.

3.3. Backbone: Conv, C3k2, SPPF và C2PSA

Các convolution stride 2 giảm dần kích thước không gian và tăng chiều kênh, tạo ra nhiều mức feature P1/2 đến P5/32. C3k2 là block chính để học đặc trưng trong họ Ultralytics gần đây. Ở các stage sâu, block có thể dùng C3k hoặc attention tùy cấu hình. Mục tiêu không phải giữ mọi pixel ở độ phân giải gốc mà xây dựng biểu diễn ngày càng giàu ngữ nghĩa với chi phí kiểm soát được. [1]


SPPF (Spatial Pyramid Pooling Fast) mở rộng receptive field bằng chuỗi max-pooling và concat. YOLO26 bổ sung shortcut trong SPPF theo phân tích source code của [2], giúp đường truyền thông tin/gradient trực tiếp hơn. C2PSA chứa PSABlock với attention và FFN, đóng vai trò bổ sung khả năng mô hình hóa quan hệ rộng hơn mà không biến toàn bộ mô hình thành Transformer. [1], [2]

3.4. Neck và hợp nhất đặc trưng đa tỉ lệ

Neck thực hiện một chuỗi upsample + concat theo hướng top-down rồi downsample + concat theo hướng ngược lại. Về trực giác, feature sâu có ngữ nghĩa mạnh nhưng thô về vị trí; feature nông có độ phân giải cao nhưng nghèo ngữ nghĩa hơn. Hợp nhất hai nguồn giúp detector giữ cả khả năng phân lớp lẫn định vị. Trong dữ liệu giao thông, cơ chế đa tỉ lệ liên quan trực tiếp đến trường hợp xe ở xa chỉ chiếm vài chục pixel trong khi xe gần camera chiếm vùng ảnh lớn.

Ba mức đầu ra P3/P4/P5 được đưa tới ba detection head. Cách tổ chức này tương ứng với nhu cầu xử lý vật thể nhỏ, vừa và lớn ở nhiều tỷ lệ. Preprint kiến trúc [2] cũng mô tả ba head gắn với các mức này. [2]

3.5. Detection head: dual-head nhưng chỉ một nhánh dùng khi suy luận mặc định



Hình 3.2. Các block chính và cấu trúc dual-head của YOLO26

Nguồn: Jocher et al. [1], Supplementary Figure S2.

Detect Head được tách thành one-to-many và one-to-one trong quá trình huấn luyện. Nhánh one-to-many tạo supervision dày, cho phép một ground-truth gắn với nhiều prediction. Nhánh one-to-one gắn mỗi object với một prediction duy nhất, phù hợp với đầu ra của end-to-end inference. [1]

Khi suy luận end-to-end mặc định, nhánh one-to-many bị loại bỏ và chỉ one-to-one được giữ lại. Vì mô hình đã học cách tạo một prediction chính cho mỗi object, pipeline không cần chạy NMS như bước hậu xử lý riêng. Đây là khác biệt bản chất so với việc "bỏ NMS bằng cách tắt một dòng code": nếu chỉ tắt NMS trên detector truyền thống, box trùng lặp vẫn còn; YOLO26 thay đổi cả cơ chế assignment và head để phục vụ đường suy luận này. [1], [7]

3.6. DFL-free regression: đơn giản hóa head

YOLOv8/YOLO11 dùng DFL để mô hình hóa mỗi tọa độ box như một phân phối trên các bin. Cách này có lợi cho localization nhưng làm tăng số output của nhánh regression và đặt một khoảng hồi quy hữu hạn. YOLO26 đặt reg_max = 1, khiến DFL trở thành identity và head hồi quy trực tiếp bốn tọa độ. Official architecture guide của Ultralytics xác nhận không còn DFL operation trong graph ONNX được export. [7]

Paper chính thức cung cấp ablation có kiểm soát cho DFL. Với YOLO26s ở 640 px, bỏ DFL làm AP tăng từ 46,0 lên 46,3; ở 1280 px, AP tăng từ 49,8 lên 51,1. Cấu hình ablation đồng thời giảm khoảng 0,3 triệu tham số, 1,4 GFLOPs và 0,2 ms latency. [1]

Bảng 3.1. Ablation DFL của YOLO26s trên COCO

Nguồn: Jocher et al. [1], Table 3.

Resolution	DFL	AP	AP_S	AP_M	AP_L
640	Có	46,0	27,3	50,4	62,8
640	Không	46,3	27,9	50,6	63,8

Resolution	DFL	AP	AP_S	AP_M	AP_L
1280	Có	49,8	36,0	55,7	61,8
1280	Không	51,1	35,9	55,2	64,0

3.7. Progressive Loss: train dần giống đường inference

Nếu hai head luôn nhận trọng số loss như nhau, one-to-one - nhánh dùng ở inference end-to-end - có thể nhận mức tối ưu chưa tương ứng với vai trò khi triển khai. Progressive Loss thay đổi tỷ trọng supervision theo thời gian: giai đoạn đầu ưu tiên one-to-many, sau đó tăng dần trọng số cho one-to-one. Cơ chế này làm objective ở cuối quá trình huấn luyện gần hơn với đường inference. [1]

3.8. STAL: xử lý điểm mù label assignment cho vật thể rất nhỏ

Task-Aligned Learning (TAL) chọn positive candidate dựa trên quan hệ hình học giữa anchor point và ground-truth box. Sau nhiều lần downsample, vật thể quá nhỏ có thể không chứa anchor point nào và nhận zero positive assignment, đồng nghĩa không tạo gradient localization/classification. STAL (Small-Target-Aware Label Assignment) được đưa vào để đảm bảo vật thể nhỏ vẫn có positive coverage. [1]

STAL liên hệ với bài toán giao thông ở trường hợp xe ở xa, người đi bộ ở góc camera hoặc đối tượng trên camera đặt cao có kích thước nhỏ. Tuy nhiên, STAL chỉ giải quyết việc cấp supervision trong train; nó không đảm bảo rằng mọi vật thể nhỏ ngoài thực tế sẽ được phát hiện. Chất lượng dữ liệu, độ phân giải, motion blur, che khuất và domain shift vẫn quyết định kết quả.

3.9. MuSGD và kết quả ablation optimizer


MuSGD kết hợp cập nhật kiểu Muon với SGD. Trong thí nghiệm detection từ scratch trên COCO, paper báo MuSGD đạt 47,4 mAP sau 500 epoch, trong khi SGD đạt 47,0 mAP sau 600 epoch; số epoch giảm 16,7% và mAP tăng 0,4 trong thiết lập được kiểm soát. [1]

Bảng 3.2. So sánh optimizer trong paper YOLO26

Nguồn: Jocher et al. [1], Table 4.

Optimizer	Epoch	COCO mAP
SGD	600	47,0
MuSGD	500	47,4

3.10. Hiệu năng công bố và điều kiện benchmark



Hình 3.3. Quan hệ accuracy-latency của YOLO26 và các real-time detector trên COCO val2017

Nguồn: Jocher et al. [1], Figure 1. Latency đo trên NVIDIA T4 với TensorRT FP16.

Paper chính thức công bố năm scale n/s/m/l/x. Ở đường đánh giá standard one-to-many + NMS, mAP lần lượt là 40,9; 48,6; 53,1; 55,0 và 57,5. Ở đường end-to-end one-to-one không NMS, mAP lần lượt là 40,1; 47,8; 52,5; 54,4 và 56,9. T4 TensorRT10 latency tăng từ 1,7 ms (n) đến 11,8 ms (x). Chênh lệch mAP giữa hai đường inference nằm trong khoảng 0,6-0,8 AP trên các scale công bố. [1]

Bảng 3.3. Benchmark detection chính thức của YOLO26 trên COCO

Nguồn: Jocher et al. [1], Table 7. CPU: Intel Xeon 2.00 GHz; GPU: T4 TensorRT10.

Model	mAP	mAP E2E	CPU ONNX	T4 TRT10	Params (M)	FLOPs (B)
			(ms)	(ms)		
YOLO26n	40,9	40,1	38,9	1,7	2,4	5,4
YOLO26s	48,6	47,8	87,2	2,5	9,5	20,7
YOLO26m	53,1	52,5	220,0	4,7	20,4	68,2
YOLO26l	55,0	54,4	286,2	6,2	24,8	86,4
YOLO26x	57,5	56,9	525,8	11,8	55,7	193,9

CHƯƠNG 4. YOLO26 TRONG BỐI CẢNH GIÁM SÁT GIAO THÔNG VIỆT NAM

4.1. Đặc trưng dữ liệu giao thông Việt Nam

Camera giao thông tại Việt Nam thường ghi nhận luồng phương tiện hỗn hợp với tỷ lệ xe máy cao, mật độ thay đổi mạnh theo thời điểm, nhiều che khuất giữa các phương tiện và khác biệt lớn về kích thước đối tượng trong cùng khung hình. Dữ liệu CCTV tại Việt Nam cũng bao gồm các điều kiện ban ngày, ban đêm, mưa, phản xạ mặt đường và chất lượng camera không đồng nhất. Các đặc trưng này được ghi nhận trong UIT-VinaDeveS22, bộ dữ liệu CCTV đô thị Đà Nẵng 2026 và các bộ dữ liệu drone của UIT. [13]-[16]

YOLO26 giải quyết từng phát hiện đối tượng: vị trí bounding box, lớp đối tượng và confidence. Các tác vụ như giữ ID theo thời gian, đếm xe theo hướng, nhận diện vượt đèn đỏ, ước lượng tốc độ hoặc đọc biển số không nằm trong đầu ra của detector và cần mô-đun bổ sung. Việc tách các chức năng này giúp chỉ tiêu đánh giá của từng tầng được xác định riêng.

4.2. Bộ dữ liệu và benchmark giao thông Việt Nam

Bảng 4.1. Nguồn dữ liệu Việt Nam liên quan trực tiếp đến vehicle detection và traffic analytics

Nguồn: [13]-[18].

Dataset / benchmark	Dữ liệu và nhãn	Truy cập	Vai trò với YOLO26
Vietnam Urban Traffic - Đà Nẵng (2026) [13]	23.364 ảnh CCTV; hơn 1,1 triệu instance; pedestrian, bicycle, motorcycle, car, bus, truck và traffic light có trạng thái. Split theo video 70/10/20.	Controlled access cho nghiên cứu phi thương mại.	Đánh giá detector trên camera nút giao cổ định; có nhãn xe máy và đèn tín hiệu.
UIT-VinaDeveS22 (2022) [14]	1.364 ảnh CCTV; 15.418 đối tượng; 7 lớp phương tiện; ngày/đêm, trời quang/mưa, mật độ khác nhau.	Có trang công bố và liên kết tải dữ liệu.	Baseline nhỏ, dễ tái lập cho phát hiện phương tiện trong bối cảnh Việt Nam.
AIC HCMC 2020 [18]	Video từ camera cố định; có ROI và MOI; bài toán phát hiện, tracking và xác định hướng/đếm phương tiện.	Repository chính thức cung cấp sample data và baseline.	Đánh giá pipeline detector + tracker + counting theo hướng di chuyển.

Dataset / benchmark	Dữ liệu và nhãn	Truy cập	Vai trò với YOLO26
UIT-Drone4 / UIT-Drone7 (2025) [15]	Ảnh UAV giao thông Việt Nam, tập trung cảnh mật độ xe máy cao; 4 và 7 lớp; có annotation orientation.	Công khai trên Zenodo; dữ liệu ảnh có dung lượng khoảng 37-38 GB mỗi bộ.	Đánh giá small-object và bài toán oriented detection từ góc nhìn trên cao.
UIT-ADrone (2023) [16]	51 video, 206.194 frame, khoảng 6,5 giờ; thu tại TP.HCM; 10 loại sự kiện bất thường; có bounding box cho detection.	Trang UIT-Together cung cấp liên kết tải.	Detector làm tăng thị giác đầu vào cho bài toán anomaly; anomaly vẫn cần mô hình thời gian.
HCMC TrafficDataset (2025) [17]	Dữ liệu đa phương thức tại TP.HCM; tập trung motorcycle detection/counting và quan hệ không gian dạng graph.	Metadata/paper công khai; quyền truy cập dữ liệu phụ thuộc nguồn phát hành.	Kết nối perception với dự báo lưu lượng và mô hình không-thời gian.

UA-DETRAC và BDD100K vẫn có giá trị làm benchmark quốc tế [9], [10], nhưng các bộ dữ liệu Việt Nam cung cấp tỷ lệ xe máy, góc camera và điều kiện lưu thông gần hơn với miền triển khai tại Việt Nam. Với nghiên cứu về camera cố định, bộ dữ liệu Đà Nẵng 2026 và UIT-VinaDeveS22 cung cấp nhãn trực tiếp cho vehicle detection; AIC HCMC 2020 bổ sung bài toán tracking và đếm theo hướng.

4.3. Hệ thống và dự án giao thông thông minh đang tồn tại tại Việt Nam

Bảng 4.2. Một số hệ thống, benchmark và dự án có nguồn công khai

Nguồn: [18]-[21].

Hệ thống / dự án	Thông tin công khai	Ý nghĩa đối với bài toán
AIC HCMC 2020 [18]	Camera giao thông cố định tại TP.HCM; ROI/MOI; baseline phát hiện - tracking - xác định hướng di chuyển.	Bài toán đếm phương tiện theo camera và hướng; có repository chính thức.
Camera AI TP.HCM [19]	Phòng CSGT TP.HCM công bố hệ thống camera AI trên nhiều tuyến đường và nút giao; phát hiện các hành vi như vượt đèn đỏ, sai làn, quá tốc độ, không thắt dây an toàn, dùng điện thoại.	Nguồn công khai mô tả nghiệp vụ và quy trình xác minh vi phạm.

Hệ thống / dự án	Thông tin công khai	Ý nghĩa đối với bài toán
Camera AI Hà Nội [20], [21]	Từ 13/12/2025, Hà Nội vận hành khoảng 1.837 camera AI tại 25 tuyến phố và 195 nút giao, hỗ trợ phát hiện 28 nhóm vi phạm. Sau ba tháng, nguồn thành phố công bố 19.304 trường hợp được hệ thống ghi nhận.	Nguồn chính quyền thành phố cung cấp quy mô vận hành và nhóm chức năng.
Nghiên cứu dữ liệu Đà Nẵng/UIT [13]-[17]	Các nhóm nghiên cứu Việt Nam công bố dữ liệu CCTV, UAV và traffic analytics phục vụ detection, counting, anomaly và dự báo lưu lượng.	Cung cấp benchmark miền Việt Nam cho việc kiểm tra model trước khi triển khai.

Các nguồn [19]-[21] không công bố kiến trúc detector nội bộ của hệ thống camera AI đô thị và không xác nhận việc sử dụng YOLO26. Vì vậy, các hệ thống này chỉ được dùng để xác định yêu cầu nghiệp vụ thực tế; không được dùng làm bằng chứng rằng YOLO26 đã được triển khai trong hạ tầng của Hà Nội hoặc Thành phố Hồ Chí Minh.

4.4. Vai trò kỹ thuật của YOLO26 trong hệ thống giao thông

Các đặc điểm của YOLO26 có liên hệ trực tiếp với camera giao thông gồm ba feature scale P3/P4/P5, STAL cho positive assignment của vật thể nhỏ, đường end-to-end NMS-free và nhiều mức kích thước model n/s/m/l/x. Tuy nhiên, ảnh hưởng của các cơ chế này trên dữ liệu Việt Nam phải được xác định bằng thực nghiệm; mAP COCO không thay thế được benchmark trên dữ liệu camera mục tiêu. [1]

Bảng 4.3. Phân tách chức năng detector và các mô-đun nghiệp vụ

Tác vụ	Vai trò của YOLO26	Thành phần bổ sung
Phát hiện xe máy, ô tô, xe buýt, xe tải, người đi bộ	YOLO26 có thể thực hiện sau khi lớp nhân phù hợp và dữ liệu được fine-tune.	Không bắt buộc mô-đun khác cho detection.
Đếm phương tiện theo hướng	YOLO26 cung cấp detection từng frame.	Tracker + ROI/MOI + logic chống đếm lặp; cấu trúc này trùng với bài toán AIC HCMC 2020.
Vượt đèn đỏ	YOLO26 có thể phát hiện xe và trạng thái đèn nếu dataset có nhãn tương ứng.	Tracking + stop line/ROI + đồng bộ trạng thái đèn + luật thời gian.
Không đội mũ bảo hiểm	Detector cần nhãn người lái/mũ bảo hiểm hoặc mô hình chuyên biệt.	Liên kết người - xe máy và logic vi phạm.
Ước lượng tốc độ	Bounding box theo frame không tạo ra tốc độ theo đơn vị km/h.	Tracking + timestamp + hiệu chuẩn camera/homography.

Tác vụ	Vai trò của YOLO26	Thành phần bổ sung
Nhận dạng biển số	YOLO26 có thể dùng để định vị biển số nếu được train cho lớp đó.	OCR/ANPR và kiểm soát chất lượng ảnh.
Ước lượng mật độ/ùn tắc	Detection cung cấp số lượng và vị trí phương tiện.	Tổng hợp theo ROI và cửa sổ thời gian; có thể kết hợp mô hình không-thời gian.

4.5. Thiết kế thực nghiệm trên dữ liệu Việt Nam

Thực nghiệm detection được tách khỏi tracking và luật nghiệp vụ. Hai cặp model cùng scale được sử dụng để so sánh: YOLO11n - YOLO26n và YOLO11s - YOLO26s. Input size, số epoch hoặc compute budget, augmentation, tập train, runtime export và thiết bị đo latency phải giữ giống nhau giữa hai model trong mỗi cặp.

Bộ dữ liệu CCTV Đà Nẵng 2026 [13] có split theo video 70/10/20 và chứa nhãn xe máy, người đi bộ, các loại xe cùng trạng thái đèn tín hiệu; bộ này phù hợp cho đánh giá detector ở nút giao cố định nhưng hiện được cung cấp theo cơ chế controlled access. UIT-VinaDeveS22 [14] có quy mô nhỏ hơn và có liên kết tải công khai, nên có thể dùng như đường thực nghiệm tái lập. Khi dùng video hoặc frame trích từ video, không trộn frame của cùng một sequence giữa train và test để tránh temporal leakage.

Chỉ số detection gồm mAP@50, mAP@50:95, AP theo kích thước, Precision, Recall và AP theo từng lớp; trong bối cảnh xe máy dày, Recall của motorcycle và AP_S cần được báo cáo riêng. Chỉ số triển khai gồm median latency, p95 latency, FPS, RAM/VRAM và kích thước model trên đúng phần cứng đích. Nếu mở rộng sang AIC HCMC 2020, tracking được đánh giá bằng IDF1/HOTA hoặc số ID switch, còn counting được đánh giá bằng sai số đếm như MAE/MAPE; mAP detection không được dùng thay cho độ chính xác đếm.

4.6. Điều kiện triển khai trên phần cứng

Benchmark chính thức của YOLO26n ở input 640 báo 2,4 triệu tham số, 5,4 GFLOPs, 38,9 ms trên CPU ONNX Intel Xeon 2.00 GHz và 1,7 ms trên NVIDIA T4 TensorRT10. Các giá trị này chỉ mô tả cấu hình benchmark của paper [1]. Camera edge, mini PC, Jetson hoặc máy chủ tại trung tâm điều hành phải được đo lại trên runtime và phần cứng thực tế. Với hệ thống nhiều camera, throughput tổng, batching, decode video, network I/O và tracker có thể tạo chi phí lớn hơn thời gian inference của detector.

Ngưỡng confidence và IoU không lấy trực tiếp từ ví dụ mặc định. Ngưỡng được xác định trên validation set của từng camera hoặc nhóm camera. Các camera ban đêm, mưa, ngược sáng hoặc có góc nhìn cao cần được tách thành các nhóm kiểm thử để phát hiện sai lệch theo điều kiện vận hành.

4.7. Giới hạn khi chuyển YOLO26 sang dữ liệu Việt Nam

Domain shift tồn tại giữa COCO và camera Việt Nam, đồng thời tồn tại giữa các thành phố, giao lộ và loại camera trong cùng một thành phố. Xe máy chiếm tỷ lệ lớn, đối tượng thường sát nhau và kích thước nhỏ; ban đêm và mưa làm tăng blur, glare và giảm contrast. STAL xử lý zero-positive assignment cho tiny object trong train nhưng không khôi phục thông tin đã mất do độ phân giải thấp hoặc che khuất nặng. [1], [13], [14]

Dữ liệu giao thông còn liên quan đến quyền riêng tư và điều kiện cấp phép. Bộ dữ liệu Đà Nẵng 2026 mô tả việc ẩn danh khuôn mặt và biển số khi nhìn thấy, đồng thời giới hạn truy cập cho nghiên cứu phi thương mại [13]. Khi thu dữ liệu bổ sung từ camera thực tế, quy trình lưu trữ, ẩn danh, thời hạn giữ dữ liệu và quyền truy cập cần được xác định trước khi đưa dữ liệu vào pipeline huấn luyện.

CHƯƠNG 5. THẢO LUẬN VÀ KẾT LUẬN

5.1. Kết quả được hỗ trợ bởi nguồn công bố

YOLO26 giữ cấu trúc single-stage backbone-neck-head và bổ sung các thay đổi DFL-free regression, dual-head NMS-free inference, Progressive Loss, STAL và MuSGD. Paper chính thức có ablation cho DFL, MuSGD và benchmark theo nhiều scale. Ở Việt Nam, đã có dữ liệu CCTV, UAV, benchmark đếm phương tiện và các hệ thống camera AI ở quy mô đô thị; các nguồn này cung cấp bối cảnh để đánh giá detector trên miền dữ liệu địa phương. [1], [13]-[21]

5.2. Giới hạn của các kết luận hiện có

Paper YOLO26 không báo cáo benchmark trên các dataset giao thông Việt Nam, do đó chưa có cơ sở từ nguồn này để xếp hạng YOLO26 trên camera Việt Nam. Mức tăng tốc CPU được công bố cho cấu hình benchmark cụ thể và không áp dụng trực tiếp cho mọi thiết bị. Các nguồn công khai về camera AI Hà Nội và Thành phố Hồ Chí Minh cũng không công bố detector nội bộ, nên không thể gán YOLO26 cho các hệ thống đó. Độ chính xác tracking, counting, speed estimation và violation detection phải được đo bằng metric riêng của từng tác vụ.

5.3. Kết luận

YOLO26 chuyển một phần trọng tâm tối ưu từ detection head và hậu xử lý sang toàn bộ đường train-inference: DFL được loại khỏi regression head, nhánh one-to-one phục vụ end-to-end inference không NMS, STAL bổ sung positive assignment cho tiny object, còn MuSGD và Progressive Loss thay đổi quá trình tối ưu. Các cơ chế này có liên quan đến yêu cầu real-time và small-object của camera giao thông nhưng hiệu quả trên miền Việt Nam phải được đo trên dữ liệu địa phương.

Trong hệ thống giao thông, YOLO26 đảm nhiệm tăng detector. Tracking, đếm phương

tiện, xác định hướng, trạng thái đèn, ước lượng tốc độ, nhận dạng biển số và luật vi phạm được triển khai ở các tầng riêng. Dữ liệu Việt Nam như bộ CCTV Đà Nẵng 2026, UIT-VinaDeveS22 và AIC HCMC 2020 cho phép xây dựng protocol đánh giá gần với camera triển khai hơn so với chỉ dùng COCO. Kết luận về ưu thế của YOLO26 chỉ được đưa ra sau khi so sánh cùng scale, cùng dữ liệu, cùng compute budget và cùng phần cứng.

TÀI LIỆU THAM KHẢO

- [1] G. Jocher, J. Qiu, M. Liu, S. Lyu, F. C. Akyon, and M. E. Kalfaoglu, “Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models,” arXiv:2606.03748, 2026.
- [2] P. Hidayatullah and R. Tubagus, “YOLO26: A Comprehensive Architecture Overview and Key Improvements,” arXiv:2602.14582, preprint, Feb. 2026.
- [3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” Proc. CVPR, pp. 779-788, 2016, doi: 10.1109/CVPR.2016.91.
- [4] A. Wang et al., “YOLOv10: Real-Time End-to-End Object Detection,” arXiv:2405.14458, 2024.
- [5] Y. Tian, Q. Ye, and D. Doermann, “YOLOv12: Attention-Centric Real-Time Object Detectors,” arXiv:2502.12524, 2025.
- [6] M. Lei et al., “YOLOv13: Real-Time Object Detection with Hypergraph-Enhanced Adaptive Visual Perception,” arXiv:2506.17733, 2025.
- [7] Ultralytics, “Ultralytics YOLO26,” official documentation, <https://docs.ultralytics.com/models/yolo26/> (accessed Sep. 5, 2026).
- [8] Ultralytics, “The impact of Ultralytics YOLO26’s faster, edge-first design,” Jan. 16, 2026, <https://www.ultralytics.com/blog/the-impact-of-ultralytics-yolo26s-faster-edge-first-design> (accessed Sep. 5, 2026).
- [9] F. Yu et al., “BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning,” Proc. CVPR, pp. 2636-2645, 2020.
- [10] L. Wen et al., “UA-DETRAC: A new benchmark and protocol for multi-object detection and tracking,” Computer Vision and Image Understanding, vol. 193, Art. 102907, 2020, doi: 10.1016/j.cviu.2020.102907.
- [11] Z. Liu, M. Zhu, B. Gao, et al., “YOLO-DC for vehicle detection using deformable convolutional networks and cross-channel coordinate attention,” Scientific Reports, vol. 16, Art. 6284, 2026.
- [12] J. Lu, J. Jia, J. Yawl, and C. Zhang, “YOLOv14: Adaptive Real-Time Object Detection for Diverse Imaging Conditions,” arXiv:2608.04720v3, Aug. 2026, preprint under review.
- [13] Q. D. N. Vo, G. N. Nguyen, and H. V. Tran, “A Large-Scale Dataset for Real-Time Vehicle Detection in Vietnamese Urban Traffic Scenes,” Computers, Materials & Continua, vol. 88, no. 1, 2026, doi: 10.32604/cmc.2026.078756.
- [14] T. Trinh and K. Nguyen, “A Vietnamese benchmark for vehicle detection and real-time empirical evaluation,” Can Tho University Journal of Science, vol. 14, no. 3, pp. 45-52, 2022, doi: 10.22144/ctu.jen.2022.042.
- [15] D. Truong, Q. Nguyen, K.-D. Nguyen, T. V. Nguyen, and K. Nguyen, “Small object

detection in aerial traffic imagery: A benchmark for motorbike-dominated road scenes,” *Journal of Visual Communication and Image Representation*, vol. 113, Art. 104603, 2025.

[16] T. M. Tran, T. N. Vu, T. V. Nguyen, and K. Nguyen, “UIT-ADrone: A Novel Drone Dataset for Traffic Anomaly Detection,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2023, doi: 10.1109/JSTARS.2023.3285905.

[17] Q.-K.-T. Nguyen, D.-D. Le, and M.-S. Dao, “HCMCTrafficDataset: Enabling Smart Mobility Solutions for Motorcycle-Dense Cities with Limited Infrastructure,” 2025 IEEE International Conference on Big Data, pp. 2962-2969, 2025, doi: 10.1109/BigData66926.2025.11402133.

[18] HCMC AI Challenge, “AI Challenge 2020 - vehicle counting sample data and baseline,” official GitHub repository, <https://github.com/hcmcaic/ai-challenge-2020> (accessed Sep. 5, 2026).

[19] Phòng Cảnh sát giao thông, Công an Thành phố Hồ Chí Minh, “Ứng dụng hiệu quả hệ thống camera AI trong công tác đảm bảo trật tự an toàn giao thông tại Thành phố Hồ Chí Minh,” Oct. 6, 2025.

[20] Cổng thông tin điện tử Thành phố Hà Nội, “Một tháng triển khai hệ thống camera AI: góp phần bảo đảm trật tự an toàn giao thông, trật tự đô thị, vệ sinh môi trường,” Jan. 14, 2026.

[21] Cổng thông tin điện tử Thành phố Hà Nội, “Ứng dụng camera AI, từng bước xử lý điểm nghẽn giao thông,” Mar. 24, 2026.